

拡張 BysGNN へのアテンション機構導入による個人消費行動予測性能の向上

高岡俊輔

2025 年 11 月 28 日

概要

本研究では、Graph Attention Network (GAT) を活用した拡張 BysGNN (ExBysGNNverGAT) を提案し、時系列データにおける個人消費行動の予測を行う。従来の BysGNN は静的グラフ構造に依存していたが、本研究では GAT のアテンション機構を統合することで、動的な空間的関係性を学習する。さらに、スパース時系列データの特性を考慮したゼロ保持データ拡張手法を適用し、予測精度の向上を実現した。36 地域グリッドの時系列データを用いた実験により、提案手法の有効性を検証した。

1 はじめに

時系列データにおける個人消費行動の予測は、都市計画、交通管理、ビジネス戦略など、様々な分野で重要な課題となっている。特に、複数地域間の空間的関係性を考慮した予測は、従来の時系列モデルでは十分に扱うことが困難であった。

既存の研究では、Busyness Graph Neural Network (BysGNN) [1] が、空間的、時間的、意味的、分類学的な文脈情報を統合して POI 訪問予測を行う手法として提案されている。しかし、BysGNN は静的グラフ構造に依存しており、時系列データにおける動的な関係性の変化を捉えることが困難であるという制約がある。

本研究では、Graph Attention Network (GAT) [2] のアテンション機構を BysGNN に統合した Extended BysGNNverGAT (ExBysGNNverGAT) を提案する。GAT のマルチヘッドアテンション機構により、時系列データにおける動的な空間的関係性を学習することが可能となる。さらに、スパース時系列データの特性を考慮し、ゼロ値を保持したままノイズを付与するデータ拡張手法を適用することで、予測精度の向上を実現した。

本論文の構成は以下の通りである。第2節では関連研究について述べ、第3節では提案手法の詳細を説明する。第4節では実験設定について述べ、第5節では実験結果と考察を示す。最後に第6節で結論を述べる。

2 関連研究

2.1 Graph Neural Networks

Graph Neural Networks (GNNs) は、グラフ構造データを扱うための深層学習手法として広く研究されている。Graph Convolutional Network (GCN) [3] は、グラフの畳み込み演算を定義し、ノードの特徴を更新する手法として提案された。Graph Attention Network (GAT) [2] は、アテンション機構を導入することで、隣接ノードへの重み付けを学習可能にし、より柔軟な関係性の表現を実現した。

2.2 時系列予測

時系列予測においては、Long Short-Term Memory (LSTM) [4] や Gated Recurrent Unit (GRU) [5] などのリカレントニューラルネットワークが広く用いられている。近年では、Transformer [6] ベースのモデルも時系列予測に適用されている。空間時系列予測においては、A3TGCN [7]、DCRNN [8]、ConvGRU [9] などの手法が提案されている。

2.3 人流・POI 予測

人流やポイントオブインタレスト (POI) の訪問予測においては、空間的関係性と時間的パターンの両方を考慮する必要がある。BysGNN [1] は、複数の文脈情報を統合して POI 訪問予測を行う手法として提案されている。しかし、静的グラフ構造に依存しているため、時系列データにおける動的な関係性の変化を捉えることが困難である。

2.4 データ拡張

時系列データにおけるデータ拡張手法としては、ノイズ付与、時間軸のシフト、スケーリングなどが用いられている。しかし、スパース時系列データにおいては、ゼロ値の意味を保持することが重要であり、従来のデータ拡張手法をそのまま適用することは適切ではない。

3 提案手法

3.1 Extended BysGNN Architecture

Extended BysGNNverGAT (ExBysGNNverGAT) は、BysGNN のアーキテクチャを基盤とし、Graph Attention Network (GAT) のアテンション機構を統合したモデルである。本モデルは、36 地域グリッドの時系列データを入力とし、各時点における個人消費行動を予測する。

3.2 Graph Attention Network Integration

GAT 層では、マルチヘッドアテンション機構を用いて、ノード間の動的な関係性を学習する。各ヘッドにおいて、アテンション係数 α_{ij} は以下のように計算される：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i\|\mathbf{W}\mathbf{h}_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\mathbf{a}^T[\mathbf{W}\mathbf{h}_i\|\mathbf{W}\mathbf{h}_k]))} \quad (1)$$

ここで、 \mathbf{h}_i はノード i の特徴ベクトル、 \mathbf{W} は学習可能な重み行列、 \mathbf{a} はアテンション重みベクトル、 \mathcal{N}_i はノード i の隣接ノード集合である。

マルチヘッドアテンションの出力は、各ヘッドの出力を連結または平均することで得られる：

$$\mathbf{h}'_i = \parallel_{k=1}^K \sigma \left(\sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \mathbf{h}_j \right) \quad (2)$$

ここで、 K はアテンションヘッド数、 σ は活性化関数である。

3.3 Zero-Preserving Data Augmentation

スパース時系列データの特徴を考慮し、ゼロ値を保持したままノイズを付与するデータ拡張手法を提案する。具体的には、非ゼロ値に対してのみガウスノイズを付与し、ゼロ値はそのまま保持する：

$$\tilde{x}_t = \begin{cases} x_t + \epsilon, & \text{if } x_t \neq 0 \\ 0, & \text{if } x_t = 0 \end{cases} \quad (3)$$

ここで、 $\epsilon \sim \mathcal{N}(0, \sigma^2)$ はガウスノイズ、 σ はノイズ強度である。この手法により、スパース性という重要な情報を保持しながら、データの多様性を増やすことができる。

3.4 Multi-Head Attention Mechanism

時系列データにおける短期および長期のパターンを捉えるため、複数のアテンションヘッドを用いる。各ヘッドは異なる時間スケールのパターンを学習し、それらを統合することで、より包括的な時系列表現を獲得する。

4 実験

4.1 データセット

実験には、36 地域グリッドの時系列データを使用した。データには、各時点における個人消費行動の情報が含まれている。データセットは学習用、検証用、テスト用に分割し、時系列の順序を保持した。

4.2 実験設定

モデルの学習には、Adam オプティマイザを使用し、学習率は 10^{-3} に設定した。バッチサイズは 32、エポック数は 100 とした。アテンションヘッド数は 8、隠れ層の次元数は 64 に設定した。

データ拡張については、拡張倍率を 1 倍、3 倍、5 倍、10 倍、20 倍の 5 通りで実験を行った。ノイズ強度 σ は、データの標準偏差の 0.1 倍に設定した。

4.3 評価指標

予測精度の評価には、以下の指標を使用した：

- 平均二乗誤差 (MSE)
- 平均絶対誤差 (MAE)
- 決定係数 (R^2)

さらに、回帰予測に加えて、二値分類評価も併用した。具体的には、予測値が閾値以上かどうかを判定し、精度、再現率、F1 スコアを計算した。

4.4 ベースライン手法

比較実験として、以下のベースライン手法と比較した：

- BysGNN (元の実装)
- A3TGCN
- DCRNN
- ConvGRU
- LSTM
- GRU

5 結果と考察

5.1 予測精度の比較

提案手法である ExBysGNNverGAT は、すべてのベースライン手法と比較して、より高い予測精度を達成した。特に、GAT のアテンション機構により、動的な空間的关系性を学習することができ、従来の静的グラフ構造に基づく手法を上回る性能を示した。

データ拡張の効果について、拡張倍率を変化させた実験を行った結果、適切な拡張倍率 (5 倍から 10 倍) において、予測精度が向上することが確認された。過度な拡張 (20 倍) では、過学習の傾向が見られた。

5.2 ゼロ保持データ拡張の効果

ゼロ保持データ拡張手法の効果を検証するため、通常 of データ拡張 (ゼロ値にもノイズを付与) と比較した。その結果、ゼロ保持データ拡張により、スパース性を保持しながら予測精度を向上させることができることが確認された。

5.3 アブレーション研究

各コンポーネントの貢献度を分析するため、アブレーション研究を行った。GAT 層の有無、データ拡張の有無、アテンションヘッド数の変化などについて検証した結果、すべてのコンポーネントが予測精度の向上に寄与していることが確認された。

5.4 地域別の性能分析

36 地域のうち、データ密度が高い地域と低い地域で性能を比較した。その結果、データ密度が低い地域においても、提案手法は良好な性能を示した。これは、ゼロ保持データ拡張と GAT のアテンション機構により、スパースデータに対しても効果的に学習できることを示している。

6 結論

本研究では、Graph Attention Network (GAT) を活用した Extended BysGNNverGAT を提案し、時系列データにおける個人消費行動の予測を行った。GAT のアテンション機構により、動的な空間的关系性を学習することができ、従来の静的グラフ構造に基づく手法を上回る性能を達成した。

さらに、スパース時系列データの特性を考慮したゼロ保持データ拡張手法を適用し、予測精度の向上を実現した。36 地域グリッドの時系列データを用いた実験により、提案手法の有効性を検証した。

今後の課題として、以下の点が挙げられる：

- 動的グラフ構造の学習手法の改善
- マルチスケール時系列処理の統合
- メタ学習による地域適応手法の検討
- 説明可能性の評価手法の開発

参考文献

- [1] Arash Hajisafi, Haowen Lin, Sina Shaham, Haoji Hu, Maria Despoina Siampou, Yao-Yi Chiang, and Cyrus Shahabi. Learning dynamic graphs from all contextual information for accurate point-of-interest visit forecasting. In *Proceedings of the 31st ACM International Conference on Advances in Geographic Information Systems*, pp. 1–12, 2023.
- [2] Petar Veličković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph attention networks. *arXiv preprint arXiv:1710.10903*, 2018.

- [3] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2017.
- [4] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, Vol. 9, No. 8, pp. 1735–1780, 1997.
- [5] Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, Vol. 30, , 2017.
- [7] Lei Bai, Lina Yao, Can Li, Xianzhi Wang, and Can Wang. Adaptive graph convolutional recurrent network for traffic forecasting. *Advances in neural information processing systems*, Vol. 33, pp. 17804–17815, 2020.
- [8] Yaguang Li, Rose Yu, Cyrus Shahabi, and Yan Liu. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. *arXiv preprint arXiv:1707.01926*, 2018.
- [9] Xingjian Shi, Zhourong Chen, Hao Wang, Dit-Yan Yeung, Wai-Kin Wong, and Wang-chun Woo. Convolutional lstm network: A machine learning approach for precipitation nowcasting. *Advances in neural information processing systems*, Vol. 28, , 2015.